Липецкий государственный технический университет

Факультет автоматизации и информатики Кафедра автоматизированных систем управления

ЛАБОРАТОРНАЯ РАБОТА №1

по дисциплине

«Бинарная классификация фактографических данных»

Студент Косенков В.Д.

Группа М-ИАП-23-1

Руководитель Кургасов В. В.

доцент, канд. пед. наук

Цель работы:

Получить практические навыки решения задачи бинарной классификации данных в среде Jupiter Notebook. Научиться загружать данные, обучать классификаторы и проводить классификацию. Научиться оценивать точность полученных моделей.

Задание кафедры

- 1. В среде Jupiter Notebook создать новый ноутбук (Notebook)
- 2. Импортировать необходимые для работы библиотеки и модули
- 3. Загрузить данные в соответствии с вариантом
- 4. Вывести первые 15 элементов выборки (координаты точек и метки класса)
- 5. Отобразить на графике сгенерированную выборку. Объекты разных классов должны иметь разные цвета.
- 6. Разбить данные на обучающую (train) и тестовую (test) выборки в пропорции 75% 25% соответственно.
- 7. Отобразить на графике обучающую и тестовую выборки. Объекты разных классов должны иметь разные цвета.
- 8. Реализовать модели классификаторов, обучить их на обучающем множестве. Применить модели на тестовой выборке, вывести результаты классификации:
 - Истинные и предсказанные метки классов
 - Матрицу ошибок (confusion matrix)
 - Значения полноты, точности, f1-меры и аккуратности
 - Значение площади под кривой ошибок (AUC ROC)
 - Отобразить на графике область принятия решений по каждому классу

В качестве методов классификации использовать:

- а) Метод к-ближайших соседей (n_neighbors = $\{1, 3, 5, 9\}$)
- b) Наивный байесовский метод
- c) Случайный лес (n_estimators = $\{5, 10, 15, 20, 50\}$)
- 9. По каждому пункту работы занести в отчет программный код и результат вывода.
- 10.По результатам п.8 занести в отчет таблицу с результатами классификации всеми методами и выводы о наиболее подходящем методе классификации ваших данных.
- 11.Изучить, как изменится качество классификации, если на тестовую часть выделить 10% выборки, 35% выборки. Для этого повторить п.п. 6 -10.

Ход работы

На Листинге 1 представлены все необходимые и импортированные библиотеки.

```
from sklearn.datasets import make_classification
import matplotlib.pyplot as plt
import pandas as pd
from sklearn.metrics import classification_report
```

Загрузка выборки

```
X, y = make_classification(
    n_samples=100, # Количество образцов
    n_features=2, # Количество признаков
    n_redundant=0, # Количество избыточных признаков
    n_informative=1, # Количество информативных признаков
    n_clusters_per_class=1, # Количество кластеров на класс
    class_sep=0.45, # Разделение классов
    random_state=78 # Random State для воспроизводимости
)

Вывод первых 15 элементов выборки
data = pd.DataFrame({'Feature 1': X[:, 0], 'Feature 2': X[:, 1], 'Label': y})
print(data.head(15))
```

Вывод первых 15 элементов выборки


```
Feature 1 Feature 2 Label
   0.618400 -0.825987 0
0
1 -1.002505 0.309745
   1.077837 0.159075
0.158532 0.534370
2
3
  0.265539 0.836729
   0.518891 0.597110
                        1
5
   0.636534 0.656617
6
                        1
7
   1.145333 1.064834
  -1.037819 -0.341347
8
   -0.462668 -0.255397
9
10 1.303928 -0.333062
11 -1.133073 -0.208877
                        0
12 -2.735665 0.152848
                         1
13 -0.047600 -0.562068
                        0
14 -0.048519 -0.812140
```

Рисунок 1 – Результат

Отобразить на графике сгенерированную выборку

```
plt.scatter(X[:, 0], X[:, 1], c=y, cmap='viridis', marker='o')
plt.xlabel('Feature 1')
plt.ylabel('Feature 2')
plt.title('Generated Classification Data')
plt.show()
```

Generated Classification Data




Разделение выборки

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=42)

# Отобразить обучающую и тестовую выборки
plt.scatter(X_train[:, 0], X_train[:, 1], c=y_train, cmap='viridis', marker='o', label='Train')
plt.scatter(X_test[:, 0], X_test[:, 1], c=y_test, cmap='viridis', marker='s', label='Test')
plt.xlabel('Feature 1')
plt.ylabel('Feature 2')
plt.title('Train and Test Data')
plt.legend()
plt.show()
```




Реализовать и обучить модели классификаторов

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive bayes import GaussianNB
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy score, precision score, recall score,
fl score, roc auc score, confusion matrix
import matplotlib.pyplot as plt
from sklearn.model selection import cross val predict
import numpy as np
# Функция для вывода результатов классификации
def print classification results (y true, y pred, model name):
   print(f"Results for {model name}:")
    print("Confusion Matrix:")
    print(confusion matrix(y true, y pred))
    print("\nClassification Report:")
    print(f"Accuracy: {accuracy score(y true, y pred)}")
    print(f"Precision: {precision score(y true, y pred)}")
    print(f"Recall: {recall score(y true, y pred)}")
    print(f"F1 Score: {f1 score(y true, y pred)}")
    print(f"AUC-ROC Score: {roc auc score(y true, y pred)}\n")
# а) Метод к-ближайших соседей
k \text{ values} = [1, 3, 5, 9]
for k in k values:
    knn model = KNeighborsClassifier(n neighbors=k)
    knn model.fit(X train, y train)
    knn pred = knn model.predict(X test)
    print classification results(y test, knn pred, f"K-Nearest Neighbors
(k = \{k\})")
# b) Наивный байесовский метод
nb model = GaussianNB()
nb model.fit(X train, y train)
nb pred = nb model.predict(X test)
print classification results(y test, nb pred, "Naive Bayes")
# с) Случайный лес
n estimators values = [5, 10, 15, 20, 50]
for n estimators in n estimators values:
    rf model = RandomForestClassifier(n estimators=n estimators,
random state=42)
    rf model.fit(X train, y train)
    rf pred = rf model.predict(X test)
    print_classification_results(y_test, rf_pred, f"Random Forest
(n estimators={n estimators})")
\# Отобразить область принятия решений для k-ближайших соседей с k=5
knn model 5 = KNeighborsClassifier(n neighbors=5)
knn model 5.fit(X train, y train)
plot decision regions (X, y, knn model 5, "K-Nearest Neighbors Decision
Regions (k=5)")
```

```
Results for K-Nearest Neighbors (k=1):
Confusion Matrix:
[[10 1]
 [ 2 12]]
Classification Report:
Accuracy: 0.88
Precision: 0.9230769230769231
Recall: 0.8571428571428571
F1 Score: 0.88888888888889
AUC-ROC Score: 0.8831168831168831
Results for K-Nearest Neighbors (k=3):
Confusion Matrix:
[[11 0]
 [ 0 14]]
Classification Report:
Accuracy: 1.0
Precision: 1.0
Recall: 1.0
F1 Score: 1.0
AUC-ROC Score: 1.0
Results for K-Nearest Neighbors (k=5):
Confusion Matrix:
[[11 0]
 [ 2 12]]
Classification Report:
Accuracy: 0.92
Precision: 1.0
Recall: 0.8571428571428571
F1 Score: 0.923076923076923
AUC-ROC Score: 0.9285714285714286
Results for K-Nearest Neighbors (k=9):
Confusion Matrix:
[[11 0]
 [ 2 12]]
Classification Report:
Accuracy: 0.92
Precision: 1.0
Recall: 0.8571428571428571
F1 Score: 0.923076923076923
AUC-ROC Score: 0.9285714285714286
Results for Naive Bayes:
Confusion Matrix:
[[11 0]
 [ 1 13]]
Classification Report:
Accuracy: 0.96
Precision: 1.0
Recall: 0.9285714285714286
F1 Score: 0.962962962963
AUC-ROC Score: 0.9642857142857143
Results for Random Forest (n_estimators=5):
Confusion Matrix:
[[11 0]
 [ 0 14]]
```

```
Classification Report:
Accuracy: 1.0
Precision: 1.0
Recall: 1.0
F1 Score: 1.0
AUC-ROC Score: 1.0
Results for Random Forest (n_estimators=10):
Confusion Matrix:
[[11 0]
 [ 1 13]]
Classification Report:
Accuracy: 0.96
Precision: 1.0
Recall: 0.9285714285714286
F1 Score: 0.962962962963
AUC-ROC Score: 0.9642857142857143
Results for Random Forest (n_estimators=15):
Confusion Matrix:
[[11 0]
 [ 0 14]]
Classification Report:
Accuracy: 1.0
Precision: 1.0
Recall: 1.0
F1 Score: 1.0
AUC-ROC Score: 1.0
Results for Random Forest (n estimators=20):
Confusion Matrix:
[[11 0]
[ 0 14]]
Classification Report:
Accuracy: 1.0
Precision: 1.0
Recall: 1.0
F1 Score: 1.0
AUC-ROC Score: 1.0
Results for Random Forest (n estimators=50):
Confusion Matrix:
[[11 0]
 [ 1 13]]
Classification Report:
Accuracy: 0.96
Precision: 1.0
Recall: 0.9285714285714286
F1 Score: 0.962962962963
AUC-ROC Score: 0.9642857142857143
```



Составим сводную таблицу для отображения результатов векторизации.

```
Model Test Size Accuracy Precision
                                                             Recall F1 Score
                           0.10 0.940000 0.892857 1.000000 0.943396
0
               KNN (k=1)
1
                KNN (k=3)
                                0.10 0.920000 0.862069 1.000000 0.925926
                KNN (k=5)
                               0.10 0.920000 0.862069 1.000000 0.925926
0.10 0.920000 0.862069 1.000000 0.925926
2
3
                KNN (k=9)
             Naive Bayes
                               0.10 0.960000 0.925926 1.000000 0.961538
4
                              0.10 0.960000 0.925926 1.000000 0.961538
5
    Random Forest (n=5)
                              0.10 0.960000 0.925926 1.000000 0.961538
0.10 0.960000 0.925926 1.000000 0.961538
6
    Random Forest (n=10)
    Random Forest (n=15)
                              0.10 0.960000 0.925926 1.000000 0.961538
    Random Forest (n=20)
                              0.10 0.960000 0.925926 1.000000 0.961538
   Random Forest (n=50)
9
10
               KNN (k=1)
                                0.35 0.942857
                                                  0.913043 0.976744
                                                                       0.943820
                               0.35 0.948571 0.905263 1.000000 0.950276
                KNN (k=3)
11
12
                KNN (k=5)
                               0.35 0.942857 0.895833 1.000000 0.945055
                              0.35 0.942857
                                                 0.895833 1.000000 0.945055
               KNN (k=9)
13
14
             Naive Bayes
                                0.35 0.977143
                                                 0.965909 0.988372 0.977011
                              0.35 0.965714 0.934783 1.000000 0.966292
15 Random Forest (n=5)
16 Random Forest (n=10)
                              0.35 0.977143 0.955556 1.000000 0.977273
17 Random Forest (n=15) 0.35 0.965714 0.934783 1.000000 0.966292 18 Random Forest (n=20) 0.35 0.977143 0.955556 1.000000 0.977273 19 Random Forest (n=50) 0.35 0.971429 0.945055 1.000000 0.971751
    AUC ROC
0 0.940000
    0.940000
    0.936800
2
    0.930400
    0.977600
4
    0.977600
6
    0.976000
    0.974400
   0.971200
8
9
    0.969600
10 0.943428
11
    0.952704
12 0.954207
13 0.951071
14
    0.989940
15 0.979227
16 0.980206
17 0.977724
18 0.977463
```

19 0.978769

Проведем классификацию с10% выборки и 35% выборки

```
# Разбиение данных на обучающую и тестовую выборки (10% тестовая)
X train, X test, y train, y test = train test split(X, y, test size=0.1,
random state=42)
# Реализация, обучение и тестирование моделей
def classify and evaluate (classifier, model name, X train, X test, y train,
y test):
   classifier.fit(X_train, y_train)
    y pred = classifier.predict(X test)
   # Вывод результатов
   print(f"\nResults for {model name} with 10% test set:")
   print("Confusion Matrix:")
   print(metrics.confusion matrix(y test, y pred))
   print("\nClassification Report:")
   print(metrics.classification report(y test, y pred))
    print(f"AUC ROC: {metrics.roc auc score(y test,
classifier.predict proba(X test)[:, 1])}")
# a) k-ближайших соседей (n neighbors = {1, 3, 5, 9})
for n_neighbors in [1, 3, 5, 9]:
   knn classifier = KNeighborsClassifier(n neighbors=n neighbors)
    classify_and_evaluate(knn_classifier, f"KNN (k={n_neighbors})", X_train,
X test, y train, y test)
# b) Наивный байесовский метод
nb classifier = GaussianNB()
classify and evaluate (nb classifier, "Naive Bayes", X train, X test, y train,
y test)
# c) Случайный лес (n estimators = {5, 10, 15, 20, 50})
for n estimators in [5, 10, 15, 20, 50]:
   rf classifier = RandomForestClassifier(n estimators=n estimators,
random state=42)
   classify and evaluate(rf classifier, f"Random Forest (n={n estimators})",
X_train, X_test, y_train, y_test)
Results for KNN (k=1) with 10% test set:
Confusion Matrix:
[[81 8]
 [ 2 84]]
Classification Report:
            precision recall f1-score support
          0
                 0.98 0.91
                                     0.94
                                                 89
                 0.91
                           0.98
                                     0.94
                                                 86
                                      0.94
                                                175
   accuracy
                  0.94 0.94 0.94
0.95 0.94 0.94
                 0.94
                                                175
  macro avg
                                                175
weighted avg
AUC ROC: 0.9434282727985367
```

Results for KNN (k=3) with 10% test set:

Confusion Matrix:

[[80 9] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00 0.91	0.90	0.95 0.95	8 <i>9</i> 86
accuracy macro avg weighted avg	0.95 0.95	0.95 0.95	0.95 0.95 0.95	175 175 175

AUC ROC: 0.9527044682518944

Results for KNN (k=5) with 10% test set:

Confusion Matrix:

[[79 10] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00	0.89	0.94	89 86
accuracy macro avg weighted avg	0.95 0.95	0.94	0.94 0.94 0.94	175 175 175

AUC ROC: 0.9542069506140579

Results for KNN (k=9) with 10% test set:

Confusion Matrix:

[[79 10] [0 86]]

Classification Report:

support	f1-score	recall	precision	
	0.94	0.89	1.00	0 1
175	0.94 0.94 0.94	0.94 0.94	0.95 0.95	accuracy macro avg weighted avg

AUC ROC: 0.9510713352495427

Results for Naive Bayes with 10% test set:

Confusion Matrix:

[[86 3] [1 85]]

CIASSIIICACIO	precision	recall	f1-score	support
0 1	0.99	0.97	0.98	89 86
accuracy macro avg weighted avg	0.98	0.98	0.98 0.98 0.98	175 175 175

Results for Random Forest (n=5) with 10% test set:

Confusion Matrix:

[[83 6] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.93	0.97	89
1	0.93	1.00	0.97	86
accuracy			0.97	175
macro avg	0.97	0.97	0.97	175
weighted avg	0.97	0.97	0.97	175

AUC ROC: 0.9792265482100861

Results for Random Forest (n=10) with 10% test set:

Confusion Matrix:

[[85 4] [0 86]]

Classification Report:

support	f1-score	recall	precision	
89 86	0.98 0.98	0.96 1.00	1.00	0
175 175 175	0.98 0.98 0.98	0.98 0.98	0.98 0.98	accuracy macro avg weighted avg

AUC ROC: 0.9802064280114973

Results for Random Forest (n=15) with 10% test set: Confusion Matrix:

[[83 6] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00 0.93	0.93	0.97 0.97	89 86
accuracy macro avg weighted avg	0.97 0.97	0.97 0.97	0.97 0.97 0.97	175 175 175

AUC ROC: 0.9777240658479226

Results for Random Forest (n=20) with 10% test set:

Confusion Matrix:

[[85 4] [0 86]]

010001110001	precision	recall	f1-score	support
0	1.00	0.96		89 86

```
0.98
                           0.98
                                     0.98
                                                175
weighted avg
AUC ROC: 0.9774627645675464
Results for Random Forest (n=50) with 10% test set:
Confusion Matrix:
[[84 5]
 [ 0 86]]
Classification Report:
             precision recall f1-score support
                         0.94
                 1.00
0.95
          0
                                    0.97
                                                  89
          1
                            1.00
                                      0.97
                                                 86
                                     0.97
                                                175
   accuracy
                  0.97
                           0.97
                                    0.97
  macro avg
                                                175
                  0.97
                           0.97
                                    0.97
weighted avg
                                                175
AUC ROC: 0.9787692709694278
# Разбиение данных на обучающую и тестовую выборки (35% тестовая)
X train, X test, y train, y test = train test split(X, y, test size=0.35,
random state=42)
# Повторение процесса с новыми тестовыми данными
# (можете скопировать и вставить код выше, изменив размер тестовой выборки)
\# a) k-ближайших соседей (n neighbors = {1, 3, 5, 9})
for n neighbors in [1, 3, 5, 9]:
   knn classifier = KNeighborsClassifier(n neighbors=n neighbors)
    classify_and_evaluate(knn_classifier, f"KNN (k={n neighbors})", X train,
X test, y train, y test)
# b) Наивный байесовский метод
nb classifier = GaussianNB()
classify and evaluate (nb classifier, "Naive Bayes", X train, X test, y train,
y test)
\# c) Случайный лес (n estimators = {5, 10, 15, 20, 50})
for n estimators in [5, 10, 15, 20, 50]:
    rf classifier = RandomForestClassifier(n estimators=n estimators,
random state=42)
    classify_and_evaluate(rf_classifier, f"Random Forest (n={n_estimators})",
X_train, X_test, y_train, y_test)
Results for KNN (k=1) with 10% test set:
Confusion Matrix:
[[81 8]
 [ 2 84]]
Classification Report:
             precision recall f1-score support
                         0.91
                  0.98
                                     0.94
                                                  89
                  0.91
                          0.98
          1
                                     0.94
                                                 86
                                      0.94
                                           175
   accuracy
```

0.98

0.98

0.98 0.98

accuracy macro avg

175

175

macro	avg	0.94	0.94	0.94	175
weighted	avg	0.95	0.94	0.94	175

Results for KNN (k=3) with 10% test set:

Confusion Matrix:

[[80 9] [0 86]]

Classification Report:

e support	f1-score	recall	precision	
	0.95 0.95	0.90	1.00	0 1
5 175	0.95 0.95 0.95	0.95 0.95	0.95 0.95	accuracy macro avg weighted avg

AUC ROC: 0.9527044682518944

Results for KNN (k=5) with 10% test set:

Confusion Matrix:

[[79 10] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00	0.89	0.94 0.95	8 9 8 6
accuracy macro avg weighted avg	0.95 0.95	0.94	0.94 0.94 0.94	175 175 175

AUC ROC: 0.9542069506140579

Results for KNN (k=9) with 10% test set:

Confusion Matrix:

[[79 10] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.89	0.94	89
1	0.90	1.00	0.95	86
accuracy			0.94	175
macro avg	0.95	0.94	0.94	175
weighted avg	0.95	0.94	0.94	175

AUC ROC: 0.9510713352495427

Results for Naive Bayes with 10% test set:

Confusion Matrix:

[[86 3] [1 85]]

	precision	recall	f1-score	support
0	0.99	0.97	0.98	89

1	0.97	0.99	0.98	86
accuracy			0.98	175
macro avg	0.98	0.98	0.98	175
weighted avg	0.98	0.98	0.98	175

Results for Random Forest (n=5) with 10% test set:

Confusion Matrix:

[[83 6] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0	1.00 0.93	0.93	0.97	89 86
accuracy macro avg weighted avg	0.97 0.97	0.97 0.97	0.97 0.97 0.97	175 175 175

AUC ROC: 0.9792265482100861

Results for Random Forest (n=10) with 10% test set:

Confusion Matrix:

[[85 4] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0	1.00	0.96	0.98	89
1	0.96	1.00	0.98	86
accuracy			0.98	175
macro avg	0.98	0.98	0.98	175
weighted avg	0.98	0.98	0.98	175

AUC ROC: 0.9802064280114973

Results for Random Forest (n=15) with 10% test set:

Confusion Matrix:

[[83 6] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00 0.93	0.93 1.00	0.97	89 86
accuracy macro avg weighted avg	0.97	0.97 0.97	0.97 0.97 0.97	175 175 175

AUC ROC: 0.9777240658479226

Results for Random Forest (n=20) with 10% test set:

Confusion Matrix:

[[85 4] [0 86]]

	precision	recall	f1-score	support
0	1.00	0.96	0.98	89
1	0.96	1.00	0.98	86
accuracy			0.98	175
macro avg	0.98	0.98	0.98	175
weighted avg	0.98	0.98	0.98	175

Results for Random Forest (n=50) with 10% test set:

Confusion Matrix:

[[84 5] [0 86]]

Classification Report:

	precision	recall	f1-score	support
0 1	1.00 0.95	0.94	0.97 0.97	8 9 8 6
accuracy macro avg weighted avg	0.97 0.97	0.97	0.97 0.97 0.97	175 175 175

AUC ROC: 0.9787692709694278

Вывод

В ходе выполнения данной лабораторной работы я получил базовые навыки работы с языком python и набором функций для анализа данных.